10 Лекция 9: градиентный спуск

Рассмотрим безусловную задачу минимизации

$$\min_x f(x),$$

где функция $f : \mathbb{R}^n = V \to \mathbb{R}$ — из класса C^1. Начиная с точки x_0, метод градиентного спуска генерирует итерации по формуле

$$x_{k+1} = x_k - h_k \nabla f(x_k). \tag{1}$$

Здесь $h_k > 0$ — длина шага. В общем случае длина шага определяется через (неточное) решение вспомогательной одномерной задачи.

10.1 Эквивариантность по отношению к замене координат

Обратим внимание на то, что разница $x_{k+1} - x_k$ — элемент из векторного пространства V, но градиент $\nabla f(x_k)$ — элемент двойственного векторного пространства V^*. Поэтому формулу (1) невозможно интерпретировать как равенство двух векторов. Её следует понимать буквально как по-координатный алгоритм вычисления новой итерации. Иными словами, неявно подразумевается, что пространства V и V^* отождествляются посредством скалярного произведения $\langle x, y\rangle = x^T y$, порождённого системой координат. Это приводит к следствиям:

- метод градиентного спуска после линейной замены координат общего вида производит другую траекторию, т.е., не является *эквивариантным* по отношению к таким заменам
- метод градиентного спуска является эквивариантным по отношению к ортогональным преобразованиям координат

В частности, это означает, что любые количественные результаты про скорость сходимости метода на каком-либо классе функций должны учитывать характеристики функций, привязанные к скалярному произведению, порождённому системой координат.

10.2 Выпуклый гладкий случай

На первом этапе мы рассмотрим класс функций $\mathcal{F}_{0,L}$ — выпуклых C^1 функций с L-липшицевым градиентом, т.е., удовлетворяющим условию

$$\|\nabla f(x) - \nabla f(y)\| \le L \cdot \|x - y\| \qquad \forall\, x, y, \tag{2}$$

где под нормой подразумевается 2-норма, порождённая системой координат.

Напомним, что функции из класса $\mathcal{F}_{0,L}$ имеют квадратичную мажоранту

$$f(y) \le f(x) + \langle \nabla f(x), y - x\rangle + \frac{L}{2}\|y - x\|^2 \qquad \forall\, x, y. \tag{3}$$

С другой стороны, выпуклые C^1 функции имеют миноранту

$$f(y) \ge f(x) + \langle \nabla f(x), y - x\rangle \qquad \forall\, x, y. \tag{4}$$

Эти неравенства позволяют доказать следующую верхнюю оценку на скорость сходимости метода градиентного спуска на классе функций $\mathcal{F}_{0,L}$.

Лемма 1. *Пусть $f \in \mathcal{F}_{0,L}$, x_0 — начальная точка, x^* — решение задачи. Тогда после N шагов метод градиентного спуска достигает точности*

$$f(x_N) - f(x^*) \le \frac{L\|x_0 - x^*\|^2}{2N}.$$

Доказательство. Отминимизируем правую часть (3) по y. Минимум мажоранты достигается в точке y, задаваемой условием оптимальности 1-го порядка

$$\nabla f(x) + L(y - x) = 0,$$

что эквивалентно $y = x - \frac{1}{L}\nabla f(x)$. Таким образом, выбирая в качестве следующей итерации x_{k+1} минимум мажоранты с центром в текущей точке x_k, приходим к методу градиентного спуска

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k) \tag{5}$$

с шагом $h = L^{-1}$.

Подставляя в (3) точки $y = x_{k+1}$, $x = x_k$ и учитывая (5), получаем

$$f(x_{k+1}) \le f(x_k) + \langle \nabla f(x_k), -L^{-1}\nabla f(x_k)\rangle + \frac{L}{2}\|L^{-1}\nabla f(x_k)\|^2 = f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2. \tag{6}$$

Подставляя в (4) точки $y = x^*$, $x = x_k$, получаем

$$f(x^*) - f(x_k) \ge -\langle \nabla f(x_k), x_k - x^*\rangle.$$

Подставляя в

$$\frac{1}{2}\|x_{k+1} - x^*\|^2 = \frac{1}{2}\| - L^{-1}\nabla f(x_k) + x_k - x^*\|^2 = \frac{1}{2}\|x_k - x^*\|^2 - L^{-1}\langle \nabla f(x_k), x_k - x^*\rangle + \frac{1}{2}L^{-2}\|\nabla f(x_k)\|^2,$$

получаем

$$\frac{1}{2}\|x_{k+1} - x^*\|^2 \le \frac{1}{2}\|x_k - x^*\|^2 + L^{-1}(f(x^*) - f(x_k)) + \frac{1}{L}(f(x_k) - f(x_{k+1})) = \frac{1}{2}\|x_k - x^*\|^2 - \frac{1}{L}(f(x_{k+1}) - f(x^*)).$$

Суммируя по $k = 0, \ldots, N-1$, получаем

$$\frac{1}{2}\|x_N - x^*\|^2 \le \frac{1}{2}\|x_0 - x^*\|^2 - \frac{1}{L}\sum_{k=0}^{N-1}(f(x_{k+1}) - f(x^*)).$$

Но в силу (6) значение целевой функции на последовательности x_k монотонно убывает. Отсюда

$$0 \le \frac{1}{2}\|x_N - x^*\|^2 \le \frac{1}{2}\|x_0 - x^*\|^2 - \frac{N}{L}(f(x_N) - f(x^*)).$$

В итоге получаем оценку

$$f(x_N) - f(x^*) \le \frac{L}{2N}\|x_0 - x^*\|^2,$$

т.е., по функционалу скорость сходимости $O(N^{-1})$. □